

LISTA 3 IA – Felipe Costa Unsonst

Questão 1:

a: A importância se dá já que permite verificar se ele realmente aprendeu padrões gerais ou apenas memorizou os dados

b: O holdout depende de uma única divisão dos dados em treino e teste, o que pode gerar resultados instáveis e pouco representativos, assim, a amostragem aleatória realiza múltiplas divisões aleatórias dos dados, treinando e avaliando o modelo várias vezes, tornando a estimativa de desempenho mais confiável.

c: $(1-2/5) = 60\%$, 6 de 10 folds compartilhados no treinamento

d: Na amostragem aleatória um mesmo exemplo não pode aparecer mais de uma vez no mesmo subconjunto, diferentemente no Bootstrap que permite que um mesmo exemplo seja selecionado várias vezes

e: Parâmetros são valores aprendidos automaticamente pelo modelo durante o treinamento, enquanto hiperparâmetros são definidos antes do treinamento e controlam o comportamento do algoritmo. Um exemplo de parâmetro seria a estrutura da árvore enquanto exemplos de hiperparâmetros incluem a profundidade máxima da árvore, o número mínimo de amostras por folha e o critério de divisão

f: O conjunto de validações é usado para estimar a habilidade do modelo durante os ajustes do hiperparametro

Questão 2: Isso ocorreu porque a avaliação por ressubstituição utiliza os mesmos dados tanto para treinar quanto para testar o modelo. resultando em uma acurácia artificialmente alta (100%), mas sem realmente aprender padrões. Para resolver isso deve existir exemplos comuns entre os testes e o treinamento.

Questão 3: $200/10 = 20$

Questão 4:

a: Os métodos ensemble combinam as previsões de vários modelos em vez de depender de apenas um reduzindo erros individuais, melhora a robustez e aumenta a capacidade de generalização.

b: A principal diferença entre eles está na forma como os modelos são treinados e combinados: bagging é paralelo e independente, boosting é sequencial e dependente, e stacking usa um modelo extra para integração.

c: A diversidade entre as árvores é garantida por considerar todas as variáveis disponíveis, cada nó avalia apenas um subconjunto aleatório delas, o que faz com que as árvores sigam caminhos diferentes e se tornem menos correlacionadas.

Questão 5: Negativo, devido a sua maior ocorrência

Questão 6:

a: Naive Bayes assume que todas as variáveis são independentes entre si, dado o valor da classe, ele considera que uma variável não influencia a outra, o que na prática nem sempre é verdade, por isso é chamado de ingênuo. No entanto, essa hipótese raramente é totalmente realista em problemas do mundo real, já que muitas variáveis costumam ter algum grau de correlação

b: Para dados categóricos, ele calcula as probabilidades com base na frequência de cada valor nas classes. Já para dados numéricos, ele normalmente assume uma distribuição normal e usa média e desvio padrão para fazer os cálculos.

Questão 7:

	idade			renda			estudante	
compra	jovem	mi	idoso	alta	media	baixa	sim	não
sim 4/10	1/4	2/4	3/4	1/4	2/4	3/4	4/4	2/4
não 6/10	3/6	0/6	2/6	4/6	1/6	1/6	1/6	3/6

$$4/10 * 1/4 * 2/4 * 1 = 0,05$$