

LISTA 7 IA – Felipe Costa Unsonst

Questão 1:

1.1: Isso acontece porque o MLP transforma cada pixel da imagem como um nó de entrada, e cada um desses nós, estão conectados a todos os nós internos. Dessa forma, dependendo da quantidade de pixels da imagem, haverá um número muito alto de multiplicações para aprender os pesos, tornando um processo, computacionalmente muito caro. Ademais, o MLP, trata todos os pixels de forma igualitária, o pixel do olho de um gato é o mesmo do que a sua pata.

1.2: Etapa1, Convolução: Pega os pixels da imagem e aplica um filtro (kernels) para procurar partes específicas, como bordas, e assim forma o feature map, (a imagem fica menor e facilita o processamento, mesmo que se perca alguns elementos da imagem, as partes principais ainda se mantêm), formando uma matriz de pixels menor.

Etapa2, Pooling: É a etapa de redução da dimensionalidade de forma a selecionar as características mais relevantes da imagem, ainda em uma matriz.

Etapa 3, Flattening: Transforma a matriz gerada nos processos anteriores em um único vetor, já que as redes neurais tradicionais não sabem ler matrizes quadradas.

Etapa 4, Rede neural densa: É a parte de classificação propriamente dita, ela recebe a lista de números anterior (que são as características resumidas da imagem) e aprende a combiná-las para tomar a decisão final.

1.3: Kernel, como dito na questão, é um filtro, com valores. Em uma imagem, cada pixel se torna uma posição na matriz, dessa forma, o kernel, através de operações de soma e multiplicação, “agrupa” uma grande quantidade de pixels em um único pixel no feature map, que é a imagem reduzida com as características principais da imagem original. Como o filtro kernel funciona com operações matemáticas, a alteração dele, muda também os valores que serão usados nas multiplicações e adições, alterando o resultado no feature map e consequentemente o resultado final.

1.4: Como dito na questão 1.2, na etapa pooling, há uma redução da dimensionalidade da matriz, para fazer isso, podemos utilizar por exemplo o max pooling, que dado uma quantidade de valores do feature map, escolhe o seu maior valor e seleciona para a nova matriz mais reduzida. A ideia do average pooling é semelhante, mas ao invés de selecionar o maior, calcula-se a média entre os valores. Por exemplo, na matriz 2x2, com os valores, 29, 15, 0 e 100, o max pooling escolheria o 100 por ser o maior valor, e o average teria o 36, que é o resultado da média entre eles.

1.5: A função da etapa flattening é transformar a matriz em um único vetor, uma vez que as redes neurais tradicionais não são capazes de ler matrizes quadradas. Fazendo isso, quando chegar na etapa 4, é possível analisar e combinar todos os pixels

Questão 2:

2.1: Um bom agrupamento deve visar maximizar a similaridade de objetos dentro de um mesmo grupo e minimizar a similaridade de objetos de grupos distintos

2.2: Não há apenas uma resposta correta, já que "agrupar", depende muito do que você está escolhendo como classificação e das características do objeto. Por exemplo, "leite" pode estar em um grupo de "alimentos não recomendados para tolerantes a lactose" ou "líquidos", revelando mais de uma possibilidade para um mesmo item.

2.3: O Kmeans é muito sensível a diferentes tamanhos, ou seja, grupos com densidades diferentes, um cluster com muitos itens junto a um cluster de poucos itens podem gerar um resultado não tão preciso. Para resolver isso, usa-se mais grupos do que o necessário, e os agrupe pequenos grupos vizinhos.

O Kmeans não funciona para clusters de formatos irregulares, logo, se métodos de agrupamento por densidade que encontra grupos de qualquer formato sem precisar definir k

Por fim, centroides iniciais aleatórios podem gerar resultados completamente diferentes a cada execução, então, deve-se utilizar de variações do próprio Kmeans que escolhe centroides iniciais mais espalhados, reduzindo o risco de convergência ruim.

2.4: O SSE, mede o quão compactos são os clusters, de forma que quanto menor for o SSE, melhor ele é, já que os pontos estão mais próximos do seu centro. Sabe-se que aumentar k (número de grupos) faz o SSE reduzir, entretanto, caso a quantidade k for igual ao numero de pontos, o SSE tem resultado 0, o que não faz sentido porque assim não resume informação. Dessa forma, o ideal é usar o Elbow Method uma vez que ele cruza o ganho de qualidade com a simplicidade do modelo, basta construir um gráfico SSE x K, e escolher o K onde a curva para de “cair rápido”.

2.5: Silhouette Index trabalha com valores de -1 a 1 para cada ponto, sendo que valores mais próximos a (-1) significa que está mais próximo aos pontos que pertencem ao outro cluster. Valores mais próximos a (0) indicam que estão próximos a fronteira dos clusters. Por fim, valores mais próximos a (1), indicia que está mais próximo aos vizinhos do seu próprio cluster. Para avaliar de forma geral, deve-se realizar uma media entre os pontos encontrados.

Questão 3:

Distancia euclidiana é dada por:

$$D(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

Assim, distancia de C1 para C2:

(Usuário 1):

Para C1:0

Para C2: $\sqrt{[(5-3)^2+(3-1)^2+(1-5)^2+(1-3)^2]} = \sqrt{(4+4+16+4)} = \sqrt{28} \approx 5,29$

Logo, grupo C1

(Usuário 2):

Para C1: $\sqrt{[(5-3)^2+(3-1)^2+(1-5)^2+(1-3)^2]} = \sqrt{(4+4+16+4)} = \sqrt{28} \approx 5,29$

Para C2: 0

Logo, grupo C2

(Usuário 3):

Para C1: $\sqrt{[(2-5)^2+(1-3)^2+(5-1)^2+(3-1)^2]} = \sqrt{(9+4+16+4)} = \sqrt{33} \approx 5,74$

Para C2: $\sqrt{[(2-3)^2]} = 1$

Logo, grupo C2

(Usuário 4):

Para C1: $\sqrt{[(4-5)^2+(3-3)^2+(4-1)^2+(2-1)^2]} = \sqrt{(1+0+9+1)} = \sqrt{11} \approx 3,32$

Para C2: $\sqrt{[(4-3)^2+(3-1)^2+(4-5)^2+(2-3)^2]} = \sqrt{(1+4+1+1)} = \sqrt{7} \approx 2,65$

Logo, grupo C2

(Usuário 5):

Para C1: $\sqrt{[(5-5)^2+(5-3)^2+(3-1)^2+(1-1)^2]} = \sqrt{(0+4+4+0)} = \sqrt{8} \approx 2,83$

Para C2: $\sqrt{[(5-3)^2+(5-1)^2+(3-5)^2+(1-3)^2]} = \sqrt{(4+16+4+4)} = \sqrt{28} \approx 5,29$

Logo, grupo C1

(Usuário 6):

Para C1: $\sqrt{[(5-3)^2+(3-1)^2+(1-5)^2+(1-3)^2]} = \sqrt{(4+4+16+4)} = \sqrt{28} \approx 5,29$

Para C2: 0

Logo, grupo C2

C1: Usuário 1 e Usuário 5

C2: Usuário 2, Usuário 3, Usuário 4, Usuário 6

Recalculo dos centroides:

C1: $(5+5)/2, (3+5)/2, (1+3)/2, (1+1)/2 = (5,4,2,1)$

C2: $(3+2+4+3)/4, (1+1+3+1)/4, (5+5+4+5)/4, (3+3+2+3)/4 = (3, 1.5, 4.75, 2.75)$

(Usuário 1):

Para C1: $\sqrt{[(5-5)^2+(3-4)^2+(1-2)^2+(1-1)^2]} \approx 1,41$

Para C2: $\sqrt{[(5-3)^2+(3-1.5)^2+(1-4.75)^2+(1-2.75)^2]} \approx 4,83$

Logo, grupo C1

(Usuário 2):

Para C1: $\sqrt{[(3-5)^2+(1-4)^2+(5-2)^2+(3-1)^2]} \approx 5,09$

Para C2: $\sqrt{[(3-3)^2+(1-1.5)^2+(5-4.75)^2+(3-2.75)^2]} \approx 0,61$

Logo, grupo C2

(Usuário 3):

Para C1: $\sqrt{[(2-5)^2+(1-4)^2+(5-2)^2+(3-1)^2]} \approx 5,56$

Para C2: $\sqrt{[(2-3)^2+(1-1.5)^2+(5-4.75)^2+(3-2.75)^2]} \approx 1,17$

Logo, grupo C2

(Usuário 4):

Para C1: $\sqrt{[(4-5)^2+(3-4)^2+(4-2)^2+(2-1)^2]} \approx 2,64$

Para C2: $\sqrt{[(4-3)^2+(3-1.5)^2+(4-4.75)^2+(2-2.75)^2]} \approx 2,09$

Logo, grupo C2

(Usuário 5):

Para C1: $\sqrt{[(5-5)^2+(5-4)^2+(3-2)^2+(1-1)^2]} \approx 1,41$

Para C2: $\sqrt{[(5-3)^2+(5-1.5)^2+(3-4.75)^2+(1-2.75)^2]} \approx 4,73$

Logo, grupo C1

(Usuário 6):

Para C1: $\sqrt{[(3-5)^2+(1-4)^2+(5-2)^2+(3-1)^2]} \approx 5,09$

Para C2: $\sqrt{[(3-3)^2+(1-1.5)^2+(5-4.75)^2+(3-2.75)^2]} \approx 0,61$

Logo, grupo C2